Estrutura de populações

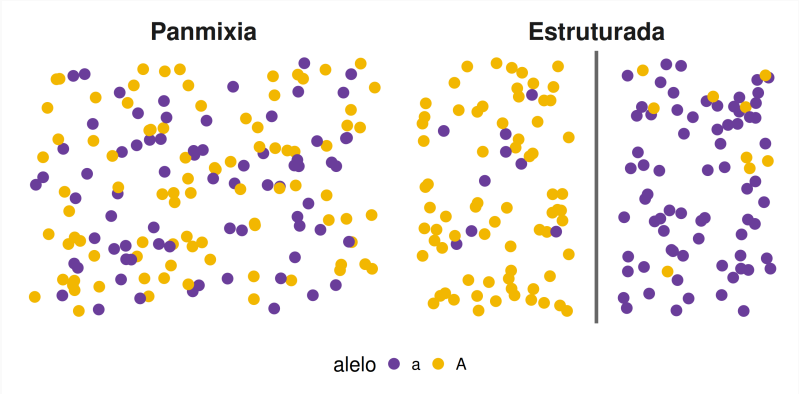
O que o STRUCTURE enxerga em populações feitas por melhoristas

Nomes dos autores

BIO641 · Genética de Populações · UFV

O que é estrutura de populações?

Populações não se cruzam ao acaso



Subpopulações → frequências alélicas diferentes

Por que isso importa?

Melhoramento

grupos heteróticos

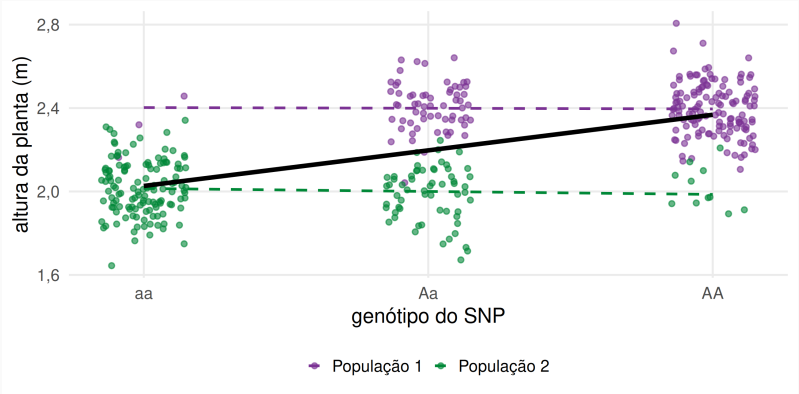
GWAS

associação falsa

Biologia

história, fluxo gênico, conservação

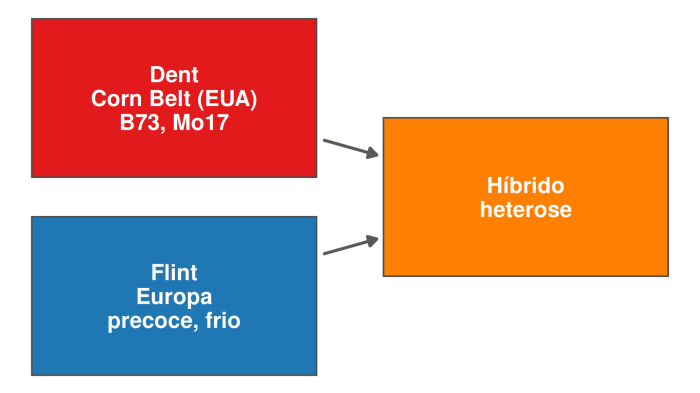
Associação falsa: erro tipo I



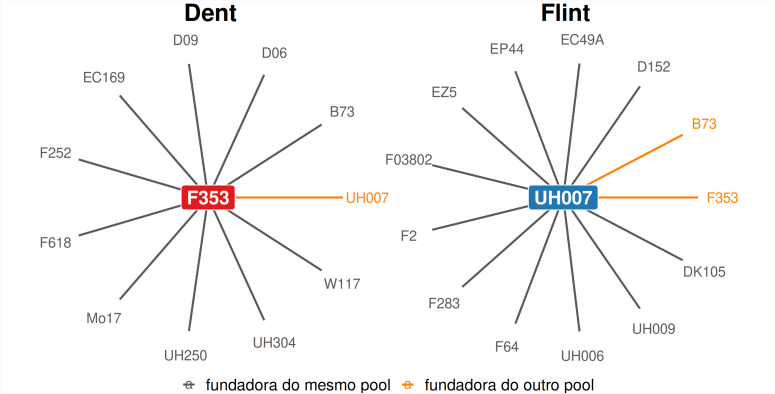
O SNP não tem efeito: a diferença vem da população

Os dados: painéis CornFed

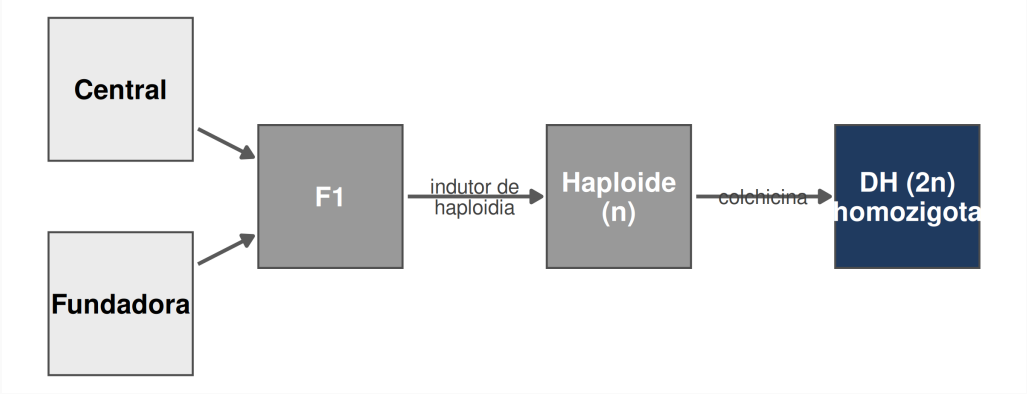
Dent × Flint: dois grupos heteróticos



Uma linha central × 10 a 12 fundadoras



Linhas duplo-haploides (DH)



Uma meiose · 50% central + 50% fundadora

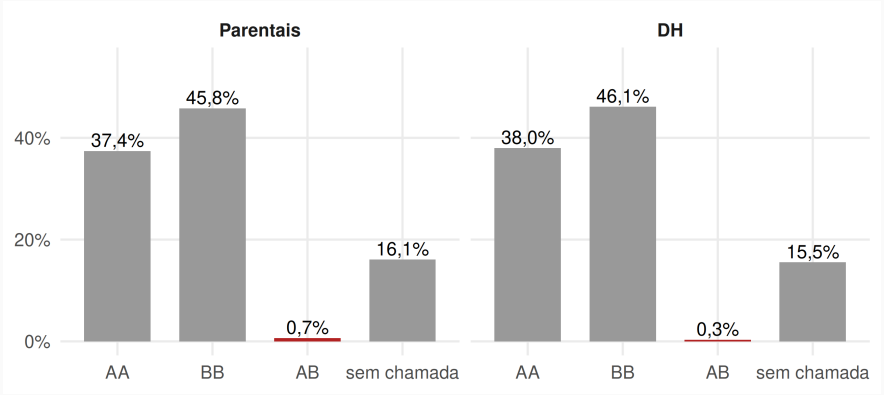
Os dados

2.290	24	23	56.110
linhas genotipadas	famílias DH	parentais	SNPs (chip 50K)

GEO **GSE50558** · Bauer et al. 2013 · Lehermeier et al. 2014

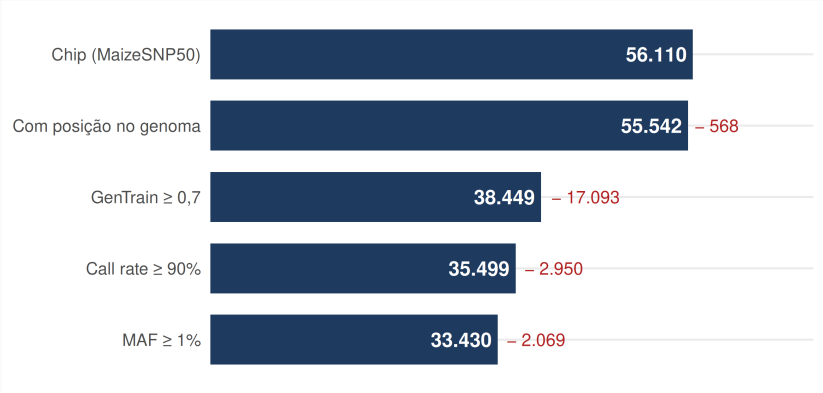
Dos SNPs aos dados limpos

O chip lê dois alelos: A e B

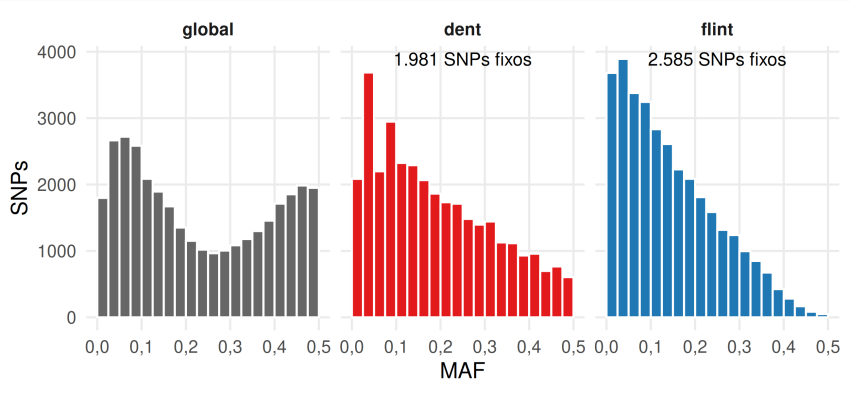


DH quase sem AB → heterozigoto = erro → dado faltante

SNPs têm erros: filtragem

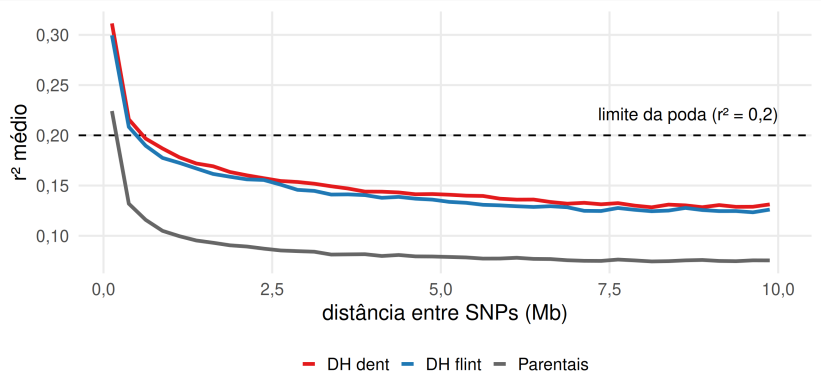


MAF: frequência do alelo raro

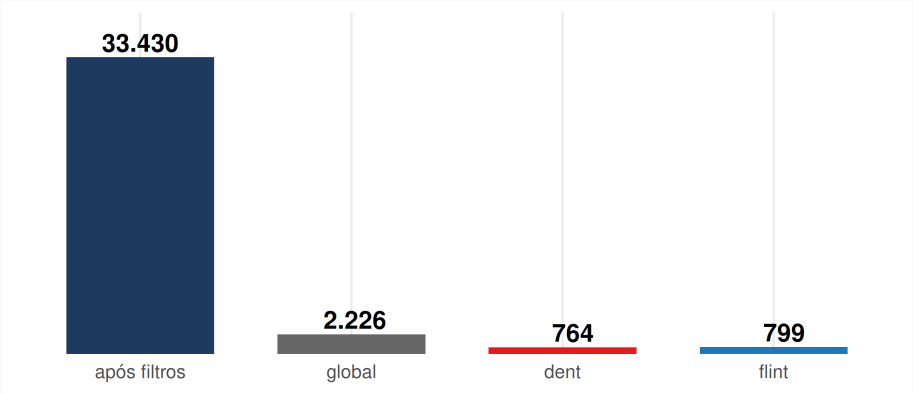


Filtros refeitos dentro de cada conjunto

Desequilíbrio de ligação (LD)



Poda por LD



Janela de 50 SNPs: de cada par com $r^2 > 0,2$, um sai

Na prática: PLINK

PLINK: o canivete suíço dos SNPs

- formatos
- filtros (CQ)
- LD e poda
- PCA, F_{ST}

Feito para **humanos**: 22 autossomos + X, Y

Milho: 10 cromossomos, sem sexuais

```
c("--chr-set", "10", "no-xy")
```

Filtros no PLINK

```
rodar_plink(
  "--bfile",   "cornfed_bruto",
  "--exclude", "gentrain_baixo.txt",  # GenTrain < 0,7
  "--remove",  "dh_faltantes.txt",    # DH > 10% NA
  "--geno",    "0.1",                 # call rate ≥ 90%
  "--maf",     "0.01",                # MAF ≥ 1%
  "--make-bed", "--out", "cornfed_cq")
```

```
2950 variants removed (--geno)
2069 variants removed (--maf)
33430 variants and 2269 samples pass
```

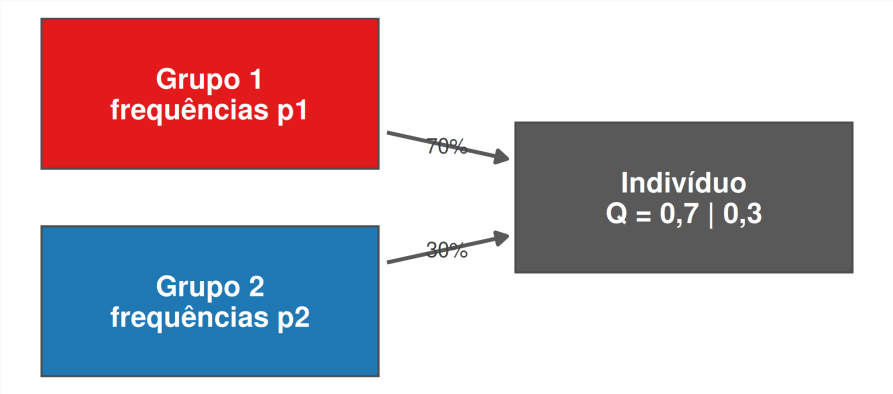
Poda por LD e exportação

```
# 1. quais SNPs ficam (janela 50, passo 5, r² 0,2)
rodar_plink("--bfile", "cornfed_cq",
            "--keep", "dent.txt",
            "--maf", "0.01", "--geno", "0.1",
            "--indep-pairwise", "50", "5", "0.2",
            "--out", "dent")

# 2. exporta no formato do STRUCTURE
rodar_plink("--bfile", "cornfed_cq",
            "--keep", "dent.txt",
            "--extract", "dent.prune.in",
            "--recode", "structure", "--out", "dent")
```

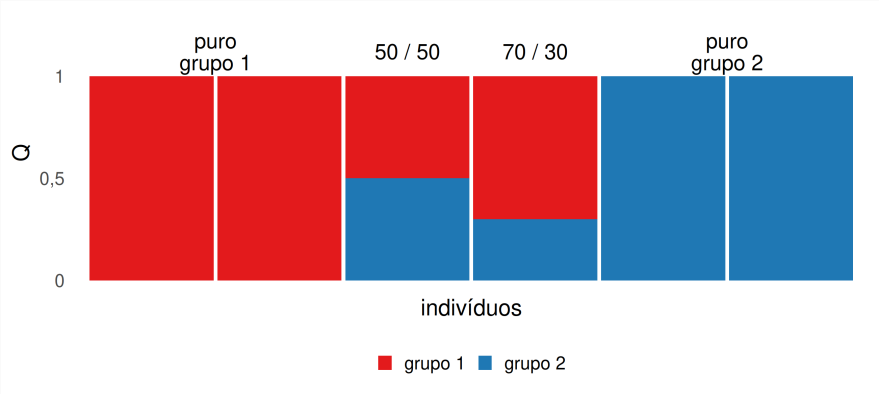
STRUCTURE

A ideia do modelo



K grupos em Hardy-Weinberg · Q = fração de cada grupo

Como ler o gráfico

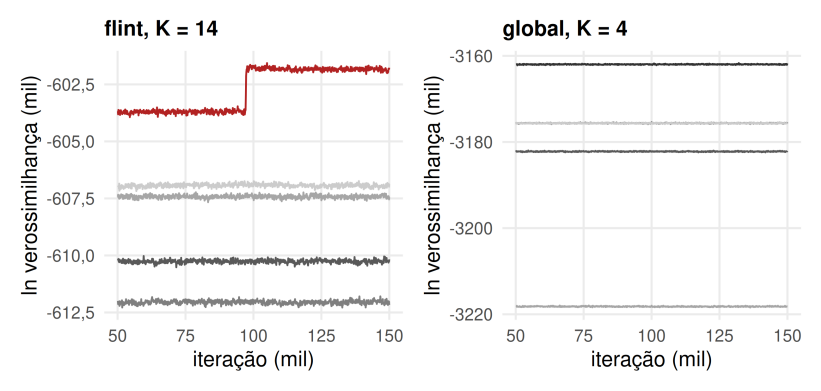


Uma barra = um indivíduo · cores = fração do genoma

Parâmetros

Parâmetro	Exploração	Cluster	Para quê
amostras	743	2.269	
K	1–6 · 1–12 · 1–14	1–8 · 1–13 · 1–14	grupos testados
réplicas	3	5	mesma resposta?
BURNIN	10.000	50.000	descartadas
NUMREPS	20.000	100.000	usadas
NOADMIX, FREQSCORR	0, 1	0, 1	modelo
RANDOMIZE	0 + `-D`	0 + `-D`	reprodutível

MCMC: burn-in e convergência



Salto → réplica instável · patamares diferentes → várias soluções

Rodando: do notebook ao cluster

```
# local: várias execuções em paralelo, 1 núcleo cada
parallel::mclapply(1:96, rodar_structure, mc.cores = 10)

# cluster UFV (PBS): um job por conjunto × K × réplica
qsub -N "$nome" -l walltime="$walltime" \
     -v CONJ=$conj,K=$k,REP=$rep,SEMENTE=$semente \
     structure_job.pbs
```

Local: 96 execuções em 6,5 h · Cluster: 169 de 175 jobs

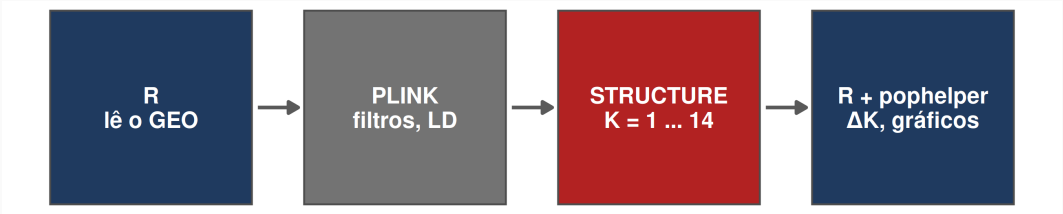
A saída: matriz Q

indivíduo	família	Q grupo 1	Q grupo 2
B73	Parental	0,20	0,80
CFD01-003	CFD01	0,61	0,39
CFD03-003	CFD03	0,00	1,00
CFF09-001	CFF09	1,00	0,00
UH007	Parental	1,00	0,00

Uma linha por indivíduo · soma = 1

R: costurando tudo

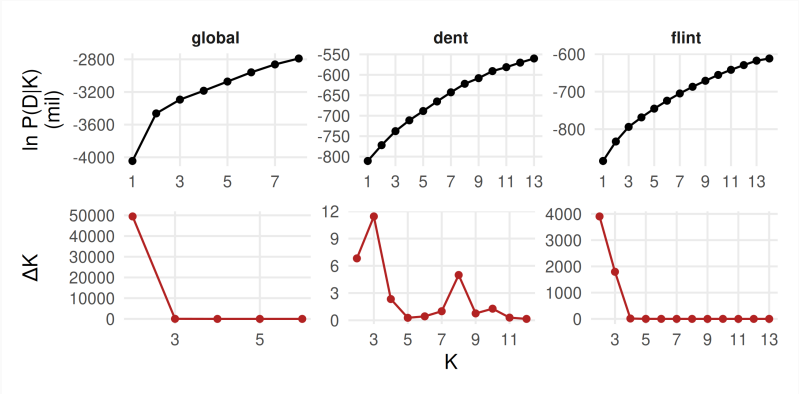
Um fluxo, um script




```
q  <- readQ(arquivos_f)              # lê as matrizes Q
ev <- evannoMethodStructure(
        summariseQ(tabulateQ(q)))    # ΔK de Evanno
q  <- alignK(q, type = "within")     # alinha as réplicas
```

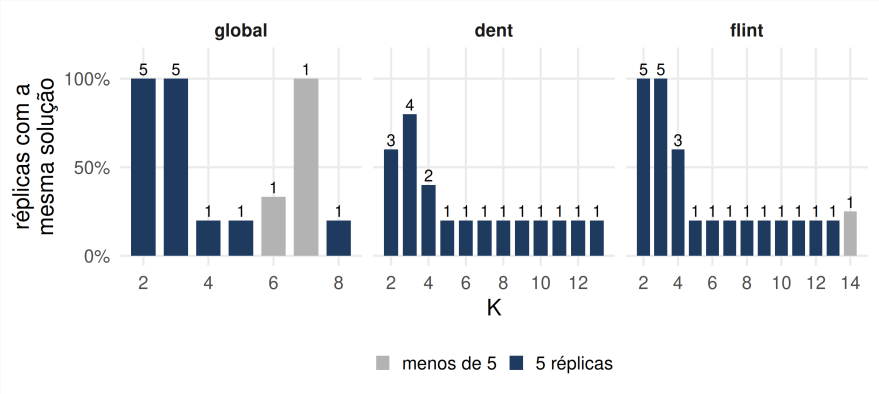
Resultados

Quantos grupos? ΔK de Evanno



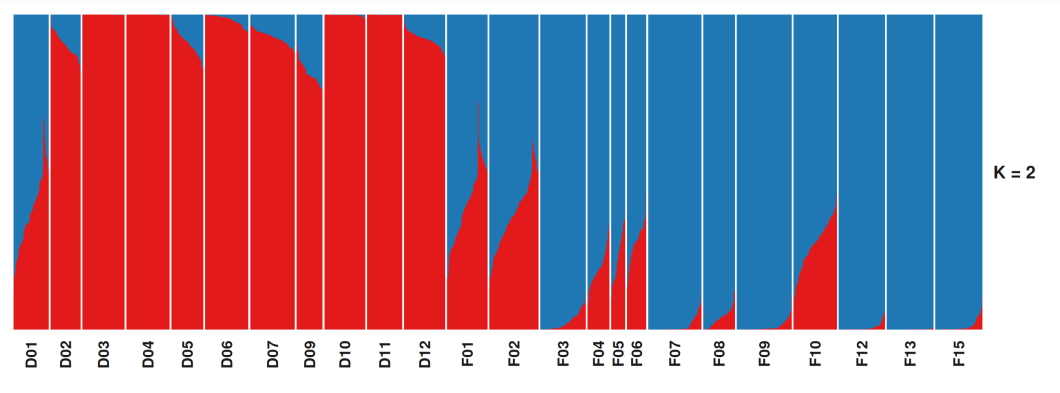
ΔK: K = 2 (global, flint) · K = 3 (dent)

As réplicas concordam?



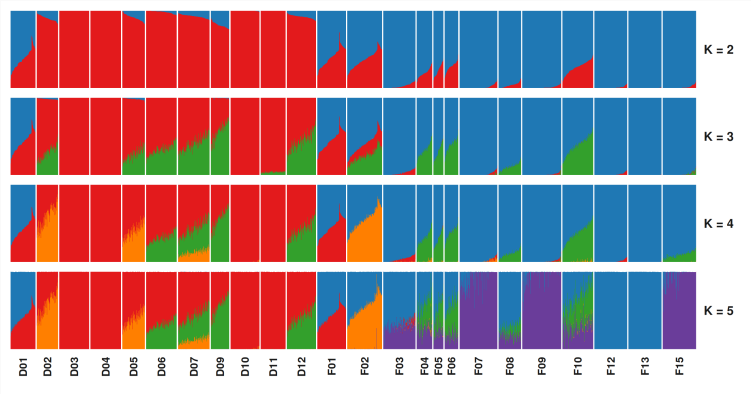
Só os K baixos se repetem

Global, K = 2: dent × flint



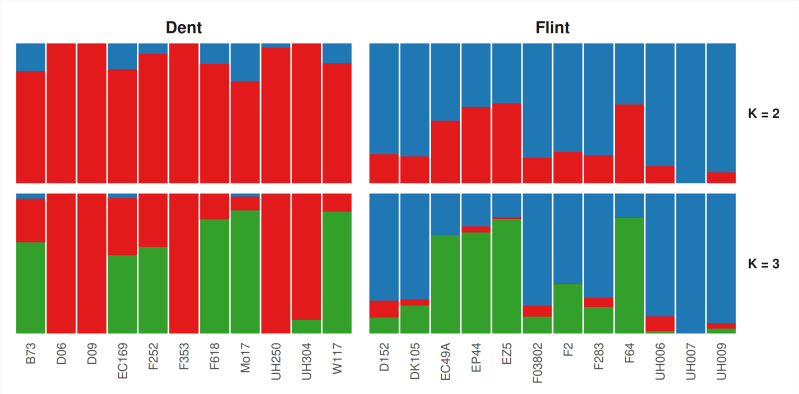
CFD01, CFF01, CFF02: ~60/40, os pais vêm dos dois pools

Global, K = 2 a 5



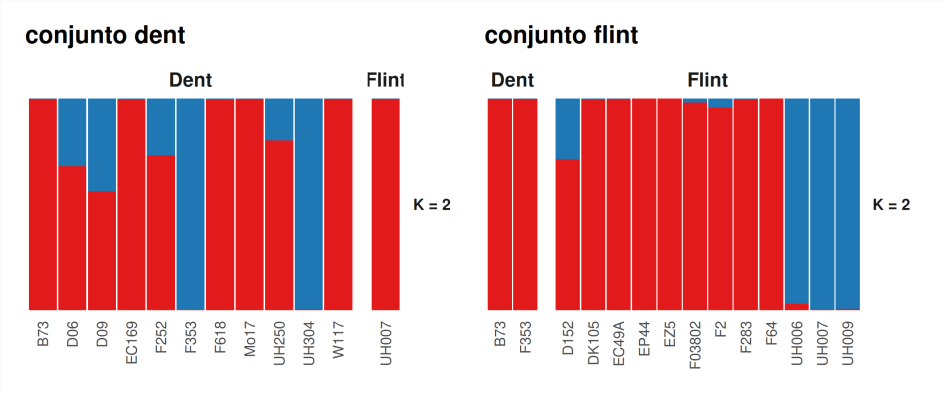
K = 4 e 5: uma solução entre várias

Os parentais



UH007 é 100% “flint”; várias fundadoras flint, não

Dentro do pool, K = 2 é a linha central

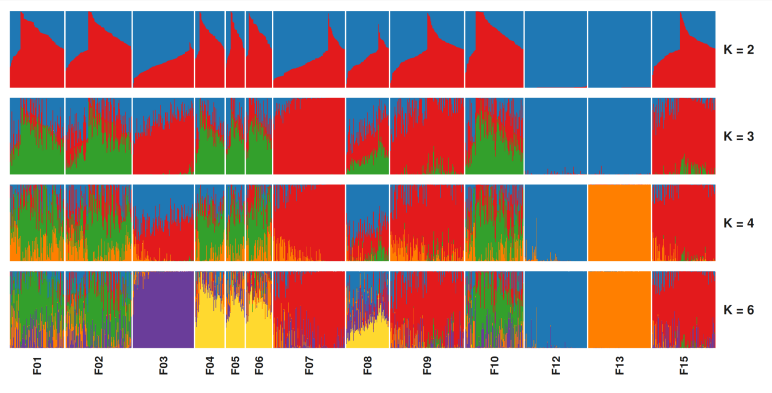


F353 (dent) e UH007 (flint) × as fundadoras

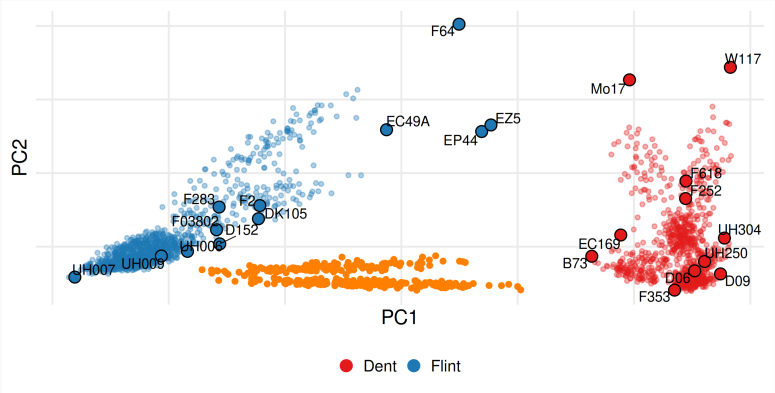
Dentro do pool Dent



Dentro do pool Flint

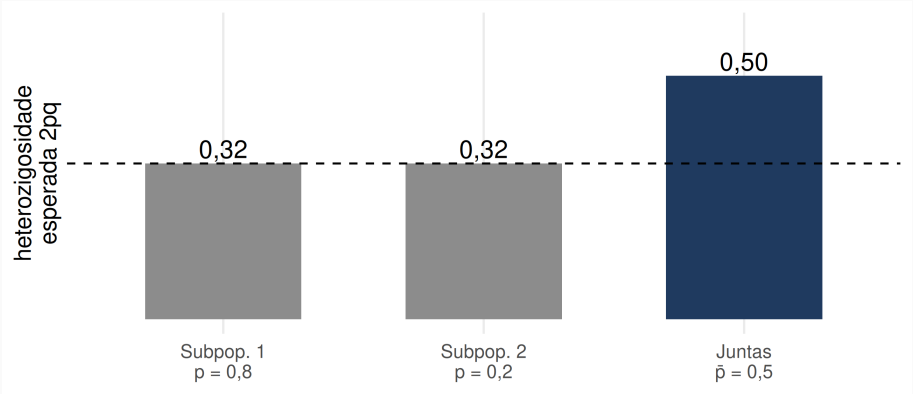


PCA: outra forma de ver



Estatísticas F

Efeito Wahlund



Juntar subpopulações → “falta” de heterozigotos

F de Wright: três níveis

$$\underbrace{F_{IS} = 1 - \frac{H_O}{H_S}}_{\text{dentro}} \qquad \underbrace{F_{ST} = 1 - \frac{H_S}{H_T}}_{\text{entre}} \qquad \underbrace{F_{IT} = 1 - \frac{H_O}{H_T}}_{\text{total}}$$

$$(1 - F_{IT}) = (1 - F_{IS})\,(1 - F_{ST})$$

F nos dados CornFed

subpopulações	H_O	H_S	H_T	F_{IS}	F_{ST}	F_{IT}
Pools (dent x flint)	0,001	0,247	0,310	0,998	0,202	0,998
Famílias dent	0,001	0,187	0,291	0,997	0,356	0,998
Famílias flint	0,001	0,161	0,247	0,996	0,348	0,998

$F_{IS} \approx 1$: DH são homozigotas

F_{ST} famílias **>** F_{ST} pools

Para levar

O que o STRUCTURE encontrou

1. **K = 2**: dent × flint, a divisão histórica
2. Dentro do pool: **linha central** × fundadoras
3. Acima disso: **famílias**, ou seja, o pedigree
4. Em população feita por melhorista, **não existe “K verdadeiro”**

Estrutura ≠ só populações naturais: parentesco também é estrutura

Referências

- Pritchard et al. 2000, *Genetics*
- Falush et al. 2003, *Genetics*
- Evanno et al. 2005, *Mol. Ecol.*
- Weir & Cockerham 1984, *Evolution*
- Yu et al. 2006, *Nat. Genet.*
- Bauer et al. 2013, *Genome Biol.*
- Lehermeier et al. 2014, *Genetics*
- Caniato et al. 2011, *PLoS ONE*
- Chang et al. 2015, *GigaScience* (PLINK 1.9)
- Francis 2017, *Mol. Ecol. Resour.* (pophelper)